学说知识资产化规范 V1.3

状态：V1.3 试行版，基于四个语料的完整实践；定义分层、版本字段与多版本并存均已实现。

目的：把「一套学说」整理成可被 AI / Agent 调用的知识资产，并规定最小可交付标准。

适用：原创学说、术语体系、思想文本、公共领域经典。

不适用：内容营销、观点生成、自动问答扩写。

1. 目标与边界

1.1 目标

让外部 AI / Agent 能以最低成本、最高保真度拿到：

- 术语定义
- 概念关系
- 原文出处
- 标准问答

1.2 硬边界

- **只收学说术语，不收人物、机构、商业信息。**
- **不自动生成问答。** 问答涉及语境与共情，必须人工撰写。
- **不做观点生成。** 系统只做检索、引用、组织，不做新主张。
- **不把「被阅读」当目标。** 唯一目标是「被调用」。

2. 数据模型

最小知识库由四类对象组成。

2.1 概念（Concept）

{

```
  "term": "元识",
  "en": "Meta-recognition",
  "aliases": ["元识行为"],
  "definition": "……",
  "definition_type": "quote",
  "editor_note": "",
  "sources": [
    {"doc_title": "元意识学说极简版（标准词表）", "section": "元意识学说的社会模型：元子社会", "quote": "……"}
  ],
  "relations": [{"to": "元知", "type": "contrast"}],
  "edition_variants": [{"edition": "乙本", "definition": "……"}],
  "status": "core"
}
```

必填：term、definition、sources（至少一条）。 可选：en、aliases、relations、status、definition_type、editor_note。

定义分层规则（V1.1 新增）：

- definition_type = "quote"：definition 必须是原文原句，逐字可核验；适用于有定义句的文本。
- definition_type = "editor"：definition 仍是原文原句，editor_note 放编者释义；适用于无定义句的文本（如道德经）。
- 任何情况下，编者释义不得伪装成原文定义；接口返回时两者必须分开。

2.2 问答（FAQ）

```
{
  "question": "什么是元识？",
  "answer": "……",
  "sources": [{"doc_title": "……", "section": "……"}],
  "type": "definition"
}
```

必填：question、answer、sources、type。 type 取值：definition / distinction / relation / citation / boundary。

2.3 引证（Evidence）

```
{"doc_title": "……", "section": "……", "quote": "……", "concept": "元识", "edition": "……"}
```

2.4 关系（Relation）

```
{"from": "元识", "to": "元知", "type": "contrast", "note": "……"}
```

type 取值：is_a / part_of / contrast / depends_on / mentions。

2.5 派生数据集

文件	用途
concepts.jsonl	概念库
faq.jsonl	标准问答
evidence.jsonl	引证
sft.jsonl	指令微调格式
concepts.csv	表格查看
knowledge-graph.json	节点 + 边

3. 抽取与裁定规则

3.1 源文档

- 优先使用**标准词表 / 术语表**，其次正文；
- 记录文档名、章节、原句；出处必须能回查；
- 同一术语多源定义时，进入比对流程；
- **无现成词表的文本，先建立「术语—原句」对照表，再进入抽取**（V1.1 新增）；
- **每份语料必须记录 `edition`（版本、来源、校勘说明）**；同一经典的多版本引证并存，不合并、不改字（V1.2 新增）；
- **不同版本之间的定义差异不判为冲突**：记入 edition_variants，正文保留主分支，其余版本并列可查（V1.3 新增）；
- 只有**同一版本内**出现差异较大的定义时，才判为冲突并进入人工裁定（V1.3 明确）。

3.2 多源定义比对

- 相似度低于阈值 → 记为冲突，进入人工裁定；
- 裁定优先级：标准词表 > 正文定义 > 举例说明；
- 裁定结果必须保留一条 `sources`，禁止无出处定义。

3.3 别名规则

- **正名不得作为别名**（防止别名反向吞并）；
- 别名写入用「不覆盖」策略（已存在则跳过）；
- 别名必须有原文依据，禁止凭语义联想添加。

3.4 禁止项

- 人物姓名、笔名、机构、联系方式、商业信息；
- 以配置项维护（如 `excluded_entities`），并在抽取、引证、问答、质检四处执行。

3.5 术语形态（V1.1 新增）

- 允许**中文数字开头**的术语（如「五事」「九地」）；只拒绝「数字 + 分隔符」的编号行；
- 允许**单字术语**（如「性」「名」），但必须在人工分类中登记，未登记的单字不入库；
- 定义长度不足一句话时，优先补足原文连续句，不自行改写。

3.6 术语边界

- 与通用语义冲突的术语（如「元意识」与 meta-awareness），必须在定义或问答中显式区分；
- 可选：维护消歧层，记录「不要答成什么」，该层可随时撤除。

4. 问答规范

- **人工撰写**，不从定义自动扩写；
- 每个核心术语至少一条定义型问答；
- 易混术语必须有辨析型问答；
- 复合问题在接口层拆分，不在问答库堆砌；

- 回答必须带出处；无出处则不得入库。

5. 质量门槛

5.1 结构检查

- 必填字段齐全；
- 出处可解析到文档与章节；
- 关系两端均存在于概念表；
- `definition_type = "editor"` 时，`definition` 仍能在原文中逐字命中，`editor_note` 非空；
- 每条 `sources` 必须带 `edition`，且与语料配置一致（V1.2 新增）；
- 不同版本的差异必须出现在 `edition_variants`，且不得同时标记为 `conflict`（V1.3 新增）。

5.2 一致性检查

- 同一术语多定义 → 冲突清单；
- 别名与正名冲突 → 报错；
- 循环依赖 → 标记。

5.3 政策检查

- 禁止项泄露 → 阻断发布；
- 问答中出现人物信息 → 阻断。

5.4 人工抽检

- 按比例抽检定义与问答；
- 抽检记录留档。

5.5 指标

指标	说明
概念数	核心 + 衍生

出处覆盖率	有出处的定义占比，目标 100%
冲突数	未裁定冲突应为 0
问答数	按术语与场景覆盖
外部评分	如 TDQS，作为参考不是目标

6. 分发规范

6.1 包与接口

- 发布为可安装包（PyPI）；
- 提供 MCP stdio 接口，最小工具集：
- `answer`：整句问答
- `concept`：取词条
- `search`：检索
- `related`：关系
- `list`：目录
- 包内自带完整知识库，安装即用，不依赖作者服务器。

6.2 数据集

- 以 JSONL / CSV / 图结构发布；
- 申请 DOI（Zenodo 等），保证可引用；
- 数据集卡片写明字段、许可、用途。

6.3 站点

- 每个概念独立 URL；
- 结构化数据：`DefinedTerm` / `FAQPage` / `Dataset`；
- 提供 `llms.txt` 与 `sitemap.xml`；
- 有稳定域名（临时隧道不算）。

6.4 目录与注册表

- 提交 MCP 官方注册表；
- 提交至少一个第三方目录（如 Glama）；
- 国内平台单独维护（语言、合规不同）。

6.5 版本与 DOI

- 包版本语义化；
- 数据集 DOI 区分「版本 DOI」与「总 DOI」；
- 每次内容变更记录变更说明。

7. 许可与合规

- 代码：MIT；
- 内容：CC BY-NC-SA 4.0（署名、非商业、相同方式共享）；
- 商业使用需另行授权；
- 引用要求：注明来源与 DOI。

8. 复现检查清单

- [ ] 选定源文档，确认版权与许可，记录 `edition`（版本/来源/校勘）
- [ ] 抽取术语与定义，记录出处
- [ ] 多源比对，冲突裁定
- [ ] 别名归一，禁止正名作别名
- [ ] 禁止项过滤
- [ ] 人工撰写问答
- [ ] 结构 / 一致性 / 政策检查通过
- [ ] 生成派生数据集
- [ ] 构建站点与结构化数据
- [ ] 打包发布，MCP 自测通过

- [ ] 申请 DOI
- [ ] 提交注册表与目录
- [ ] 记录版本与变更

9. 验证状态与待验证项

已验证（V1.3）

1. **四语料复现**：孙子兵法（13 概念）、荀子·正名（12 概念）、道德经（10 概念），引文核验均 100%；
2. **定义分层**：道德经全部词条 `definition_type=editor`，原文句与编者释义在数据、接口、页面三层分离；
3. **版本字段**：四份语料均已回填 `edition`，站点、接口与数据集均显示版本；
4. **多版本并存**：不同版本的定义差异记入 `edition_variants` 且不判冲突；同版本差异仍判冲突（合成语料测试覆盖）；
5. **远程 MCP**：Streamable HTTP 已实现并部署，令牌、限流、批量请求可用。

待验证（V1.4）

6. **真实多版本语料**：用同一经典的两个真实版本跑通全流程；
7. **问答质量评估**：人工抽检之外的客观指标；
8. **多人协作**：术语裁定如何留痕、如何合并；
9. **跨语言**：中英术语映射与检索一致性。

10. 版本记录

版本	日期	说明
V1.0	2026-10-30	首版（试行），基于元意识学说实践
V1.1	2026-10-31	增加术语形态规则、定义分层、三段复现结论；远程 MCP 已验证

V1.2	2026-10-31	增加 `edition` 版本字段；四语料回填；站点/接口/数据集显示版本
V1.3	2026-11-01	增加 `edition_variants`：不同版本并存不判冲突，同版本差异仍判冲突