面向 AI 调用的学说知识资产化：方法、四语料复现与定义分层

作者：元意识（重庆）人工智能科技有限公司 • MCAI 研究组

版本：预印本 v1.1 • 2026-10-31

摘要：大语言模型在回答非主流学说时，常出现三类偏差：未收录而按字面猜测、以同名概念替换原概念、以及似是而非的混合表述。本文提出一套把思想学说转化为可被 AI 与 Agent 调用的知识资产的方法，包含四个环节：术语抽取与多源冲突裁定、问答的人工撰写、发布前的质量门槛、以及多形态分发（软件包、MCP 接口、开放数据集、结构化站点与 DOI）。方法首先在元意识学说上完成端到端实现，构建了含 64 个概念、122 组标准问答、270 条概念关系与 213 条原文引证的知识库；随后在《孙子兵法》《荀子·正名》《道德经》三份公共领域文本上复现，分别得到 13、12、10 个概念，引证核验均为 100%。复现暴露了四类规则缺口：无词表文本需先建立「术语—原句」对照；中文数字开头与单字术语需要有条件放行；无定义句的文本必须把原文句与编者释义分层。本文给出相应修订，并讨论版本差异对引文对齐的影响。

关键词：知识资产；学说数字化；模型上下文协议；知识图谱；数字人文

1 引言

大语言模型对某一学说的回答质量，取决于该学说在其训练语料与检索范围内的呈现方式。对于尚未进入主流语料的学说，常见三类偏差：

1. **未收录**：模型未接触过该学说，按字面语义猜测；
2. **语义替换**：模型以同名或近名概念替换原概念，例如把「元意识」理解为心理学的 meta-awareness；
3. **混合表述**：模型给出似是而非的答案，读者难以区分哪部分来自原文、哪部分是模型补充。

第三类最难识别。其本质不是模型能力不足，而是缺少一个机器可读、可调用、可追溯的入口。

本文的主张是：与其期待模型「记住」某一学说，不如把学说工程化为可被调用的知识资产，使模型在需要时能够检索、引用并回查出处。

本文的贡献有三点：其一，把转化路径写成可执行流程；其二，在四个语料上完成端到端复现；其三，给出「定义分层」与「术语形态」两组规则，用于处理无定义句的文本与单字术语。

2 相关工作

知识组织领域已有成熟实践：本体与知识图谱用于表达概念及其关系；Schema.org 提供 `DefinedTerm`、`FAQPage`、`Dataset` 等结构化标记；`llms.txt` 为语言模型提供站点索引；模型上下文协议（MCP）为 AI 应用提供标准化的工具调用接口。上述工作分别解决了「如何表达」「如何标记」「如何索引」「如何调用」，但较少讨论：**一套原创学说如何从原始文本，稳定地转化为上述形态，并保持术语一致性。**

本文的贡献在于把这条转化路径写成可执行的流程，并以四个语料给出实现与复现。

3 方法

方法分为四个环节。

3.1 术语抽取与冲突裁定

- 仅从词表类与模型类文档抽取定义，叙事文本只作为引证；
- 同一术语多源定义时，按文档优先级选主分支，其余保留为来源；相似度低于阈值记为冲突，进入人工裁定；
- 正名不得作为别名，避免别名反向吞并正名；
- 建立禁止项清单（人物、机构、商业信息），在抽取、引证、问答与质检四处执行；
- 无现成词表的文本，先建立「术语—原句」对照表，再进入抽取；
- 允许中文数字开头的术语（如「五事」「九地」），只拒绝「数字 + 分隔符」的编号行；
- 允许单字术语（如「性」「名」），但必须在人工分类中登记。

3.2 定义分层

有定义句的文本，`definition` 直接取原文，逐字可核验。无定义句的文本（如《道德经》），任何「定义」都是后人的解释，因此必须分层：

- `definition` 仍是原文句，不做改写；

- `editor_note` 单独存放编者释义，并明确标注「非原文」；
- 接口、页面与数据集均分开呈现，禁止把编者释义伪装成原文定义。

3.3 问答的人工撰写

问答分五类：定义、辨析、关系、引证、边界。每个核心术语至少一条定义型问答；易混术语必须有辨析型问答；复合问题在接口层拆分，而非在问答库中堆砌。问答不采用自动生成，原因是自动生成会抹平术语的细微差别。

3.4 质量门槛

发布前需通过五类检查：

- 结构：必填字段齐全，出处可解析，关系两端存在；
- 一致性：同一术语多定义、别名与正名冲突、循环依赖；
- 政策：禁止项泄露；
- 引文：逐字命中，字符区间可回查；
- 抽检：人工按比例抽查定义与问答。

核心指标为「出处覆盖率」，目标为 100%；未裁定冲突数应为 0。

3.5 多形态分发

同一份源头数据发布为五种形态：

4. 可安装软件包，内置完整知识库；
5. MCP 接口，提供回答、取词条、检索、关系、目录五类工具；
6. 开放数据集（JSONL / CSV / 图结构），申请 DOI；
7. 结构化站点，每个概念独立 URL，带 `DefinedTerm`、`FAQPage`、`Dataset` 标记与 `llms.txt`；
8. 目录与注册表收录，便于被发现。

远程 MCP 采用 Streamable HTTP，令牌鉴权、限流与批量请求均已在部署实例上验证。

4 案例与复现

4.1 元意识学说

以元意识学说为对象，按上述流程构建知识库，结果如下：

项目	数量
概念	64（58 个主词条 + 6 个衍生术语）
标准问答	122
概念关系	270
原文引证	213
语料规模	8 份文档 / 953 段 / 115,247 字

发布情况：

- PyPI 包 `mcai-knowledge`，包内自带完整知识库；
- MCP 官方注册表收录，提供 5 个工具；
- Zenodo 数据集，DOI `10.5281/zenodo.23789330`，许可 CC BY-NC-SA 4.0；
- 静态站点提供逐概念页面与 `llms.txt`；
- 第三方目录收录。

4.2 三份公共领域文本的复现

为检验方法是否依赖特定内容，选取三份公共领域文本，用同一套流水线复现：

语料	概念	问答	关系	引证核验	定义类型
元意识学说	64	122	270	55/55	原文
孙子兵法	13	17	6	13/13	原文
荀子·正名	12	5	9	12/12	原文
道德经	10	8	7	10/10	原文 + 编者释义

复现过程暴露的规则缺口与修订：

问题	表现	修订
中文数字开头术语	「五事」「九地」被当作编号丢弃	只拒绝「数字 + 分隔符」
单字术语	「性」「名」等被长度规则拒绝	人工分类登记后放行
无词表文本	古典文本没有现成定义行	先做「术语—原句」对照
无定义句文本	任何定义都是解释	定义分层：原文句 + 编者释义

4.3 一个版本问题

《道德经》不同版本字句不同：所据直译本作「见素抱扑」「水利万物」，通行本多作「见素抱朴」「水善利万物」。复现时未按通行本「更正」，而是逐字保留所据版本。这说明：**同一经典的不同版本，字句不同，引文必须与版本绑定**，否则跨版本的引文无法对齐。本文将其列为下一版规范的修订项。

5 讨论

5.1 适用边界

本方法适用于有稳定文本来源、术语边界相对清晰的学说或知识体系；不适用于以观点生成为目标的内容生产场景。方法明确不自动生成问答，也不做观点生成。

5.2 局限

9. **外部采用证据不足**：数据集与接口已公开，但尚无第三方引用、复用或调用数据；
10. **翻译问题**：英文材料依赖机器翻译，术语译法未统一，暂未构建英文知识库；
11. **形式化不足**：核心概念尚未数学化，模型只能引用而不能据此推理；
12. **版本未入模型**：语料尚未记录版本字段，多版本引证无法自动对齐。

5.3 后续工作

- 在语料与引证模型中记录 `edition`（版本、来源、校勘），支持多版本引证并存；

- 构建经作者逐条裁定的英文术语表，再考虑英文知识库；
- 评估问答质量的客观指标，减少对人工抽检的依赖；
- 收集第三方调用与引用数据，作为方法有效性的外部证据。

6 结论

把学说转化为可被 AI 调用的知识资产，关键不在于让模型记住内容，而在于让每次调用都能拿到准确、可回查的版本。本文给出的流程在一个原创学说与三份公共领域文本上完成了端到端实现，并公开了数据与接口。其有效性仍需外部采用与更多语料来检验。

参考文献

[1] Anthropic. Model Context Protocol Specification. 2025.

[2] Schema.org. DefinedTerm, FAQPage, Dataset. https://schema.org

[3] Zenodo. MCAI Knowledge Base. DOI: 10.5281/zenodo.23789330, 2026.

[4] 元意识学说极简版（标准词表）. 内部资料, 2026.

[5] 知识资产通过 AI 分发实现数字永生的操作手册. 内部资料, 2026.

[6] llmstxt.org. llms.txt 提案.

[7] 孙武. 孙子兵法. 公共领域.

[8] 荀况. 荀子·正名. 公共领域.

[9] 老子. 道德经. 公共领域.

[10] MCAI 研究组. 学说知识资产化规范 V1.1. 内部资料, 2026.